

Machine Learning

# 8장 차원 축소(Dimension reduction)

---

고려대학교 통계학과  
박유성



# Contents

- 01 차원 축소(Dimension reduction)
- 02 PCA (Principal Component Analysis)
- 03 LDA (Linear Discriminant Analysis)
- 04 MDS (Multidimensional Scaling)

# 01 차원 축소(Dimension Reduction)

- 이미지 자료나 DNA 자료들은 입력변수의 차수(dimension)이 높은 경우가 대부분임.
- 해결 방안
  - 1) 불필요한 특성 변수 제거
  - 2) 특성변수  $X_{(n \times d)}$  의 정보 대부분을 가진 새로운 변수로 차원 축소
- 본 장에서는 2)에 대해서 다루며 이는 아래와 같이 표현될 수 있음.

$$\mathbf{x}_i \longrightarrow \mathbf{z}_i = \mathbf{w}^T \mathbf{x}_i$$

이때  $\mathbf{x}_i$ 는  $d \times 1$ 인 벡터,  $\mathbf{w}$ 는  $d \times l$  ( $l \ll d$ )인 벡터,  $i = 1, \dots, n$ 임.

# SVD (Singular Value Decomposition)

- (8.1)과 같이 표현되는 것을 행렬  $X$ 의 SVD라고 함.

$$X_{n \times d} = U_{n \times n} \Lambda_{n \times d} V_{d \times d}^T \quad (8.1)$$

이때  $U$ 와  $V$ 는 직교 행렬(즉,  $U^T U = I$ ,  $V^T V = I$ )이며

$\Lambda$ 는 최대  $r = \min(n, d)$  개의 singular 값들이 대각원소인 대각행렬임.

- $n \geq d$  라고 가정하면 (8.1)식은

$$X_{n \times d} = \tilde{U}_{n \times d} \tilde{\Lambda}_{d \times d} V_{d \times d}^T \quad (8.2)$$

이때  $\tilde{\Lambda}$ 는  $\Lambda$ 에서 singular 값이 0인 행을 제거한 행렬,

$\tilde{U}$ 는  $U$ 에서  $\tilde{\Lambda}$ 에 대응하는 부분행렬임.

# SVD (Singular Value Decomposition)

- 그러면 (8.2)는  $\tilde{U}\tilde{U}^T = I$ 가 되어  $X^T X = \tilde{V}\tilde{U}^T \tilde{U} \tilde{\Lambda} \tilde{V}^T = \tilde{V} \tilde{\Lambda}^2 \tilde{V}^T$ 이므로

$$(X^T X) V = V \tilde{\Lambda}^2 \quad (8.3)$$

이는 고유값  $\tilde{\Lambda}^2$ 와 이에 대응하는 고유벡터 행렬  $V$ 를 구하는 방정식임.

- 마찬가지로  $XX^T = \tilde{U} \tilde{\Lambda} \tilde{V}^T \tilde{V} \tilde{\Lambda} \tilde{U}^T = \tilde{U} \tilde{\Lambda}^2 \tilde{U}^T$ 이므로

$$(XX^T) \tilde{U} = \tilde{U} \tilde{\Lambda}^2 \quad (8.4)$$

그러므로 (8.3)과 (8.4)에서의  $\tilde{\Lambda}^2$ 는 같다는 것을 알 수 있음.

- 그러므로  $S^2 = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^T = \frac{1}{n} X^T X$ 에 대한 고유벡터 행렬은  $V$ , 고유값은  $\frac{1}{n} \tilde{\Lambda}^2$

## 02 PCA (Principal Component Analysis)


- PCA는 특성변수를 사용하여 설명력이 높은 벡터를 찾아 차원을 축소함.
- 즉 (8.2)에서 가장 큰  $l$  ( $l < d$ )개의 고유값에 대응되는 고유벡터를 이용함.
- (8.2) 식에서 가장 큰  $l$ 개의 고유값을 이용하므로

$$X_{n \times d} \approx U_{n \times l}^* \Lambda_{l \times l}^* V_{l \times d}^{*T} \quad (8.5)$$


이때  $\Lambda_{l \times l}^*$ 는 고유값의 크기가 하위  $(d-l)$ 인 행을 제외한  $\tilde{\Lambda}_{d \times d}$ 의 부분행렬,  
 $V_{l \times d}^{*T}$ 는  $\Lambda_{l \times l}^*$ 에 대응되는 고유벡터 행렬임.

- (8.5)에 의해 주성분은  $w_{d \times l} = V_{d \times l}^*$ 이며 새로운 특성변수  $z_i = w^T x_i$ 가 됨.

## 특성변수 $X$ 가 2차원인 경우



<주성분  $w_1$ 과  $w_2$ >



< $w_1^T x$  :  $w_1$ 에의  $x$ 의 projection>

- $w_1$ 은 자료의 분산이 가장 큰 축임.
- $w_2$ 은  $w_1$ 과 직교하면서 두 번째로 자료의 분산이 큰 축임.
- $w_1^T x$  은  $x$ 를  $w_1$ 에 projection한 것임.
- 즉  $l$ 개의 주성분을 이용할 때는  $l$ 개의 주성분에 projection한 것임.

# Randomized PCA

- 자료의 크기 또는 특성변수의 크기가 매우 크면 주성분  $w$  를 구하기 위한 SVD 시 계산이 불가능하거나 시간이 많이 소요됨.
- 이 경우에 Randomized PCA가 유용함.
- Randomized PCA는 QR 분해를 이용하여 행렬의 SVD를 함.
- 행렬  $A_{(m \times n)}$  (rank는  $k$ )에 대한 SVD는 다음 장과 같이 계산됨.



# Randomized PCA

- 행렬  $A_{(m \times n)}$  (rank는  $k$ )에 대한 SVD

1) 우선 확률변수 행렬  $P_{(n \times (k+p))}$  ( $p \geq 0$ )을 정의함. (이때 행은 서로 독립이며 열은 iid한 정규분포로부터 뽑은 확률면수임.)

2)  $Y = A \times P$ 를 정의한 후  $Y$ 에 대해 QR분해를 하면  $Y = Q \times R$ 이 됨.  
이때  $R$ 은 상삼각행렬이며  $QQ^T A$ 로  $A$ 를 근사할 수 있음.

3)  $B = Q^T A$ 로 정의하면 이는  $(k+p) \times n$  행렬이 되고 이를 SVD함.  
그러면  $B = \hat{U} \Lambda V^T$ 가 되어  $QQ^T A = QB$ 이므로  $U = Q\hat{U}$ 라 하면  
 $QQ^T A = U \Lambda V^T$  임.

4) 그러므로  $A \approx U \Lambda V^T$ 로 분해됨.

# Kernelized PCA

- PCA는 선형 변환이고 kernelized PCA는 비선형 변환임.
- 특성변수  $\mathbf{x}$ 를 비선형  $h(\mathbf{x})$ 로 전환한 후 이에 대해 PCA를 하여 차원축소를 하는 방법임.
- 비선형  $h(\mathbf{x})$ 로 전환하였으므로

$$S_h^2 = \frac{1}{n} \sum_{i=1}^n h(\mathbf{x}_i) h^T(\mathbf{x}_i) = \frac{1}{n} H^T(X) H(X)$$

,  $\mathbf{x}_i$ 는  $d \times 1$  행렬,  $h(\mathbf{x}_i)$ 는  $k \times 1$  ( $k > d$ ) 행렬이며

$$H(X) = \begin{bmatrix} h_1(\mathbf{x}_1) & h_2(\mathbf{x}_1) & \cdots & h_k(\mathbf{x}_1) \\ \vdots & & & \vdots \\ h_1(\mathbf{x}_n) & h_2(\mathbf{x}_n) & \cdots & h_k(\mathbf{x}_n) \end{bmatrix} \text{임.}$$

# Kernelized PCA

- $S_h^2$ 의 고유벡터, 고유값 방정식은  $S_h^2 V = V\Lambda$ 라 하면 새로운 변수는

$$Z(h) = H(X) V \quad (8.6)$$

가 됨.

- $V = \frac{1}{n} H^T(X) Z(h) \Lambda^{-1}$ ,  $S_h^2 = \frac{1}{n} H^T(X) H(X)$  이므로 (8.6)에 대입하면

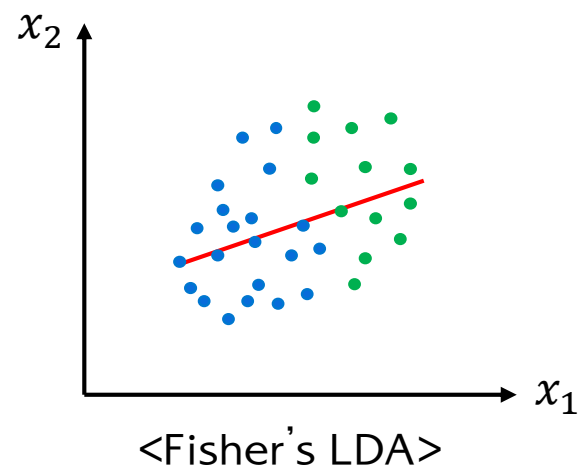
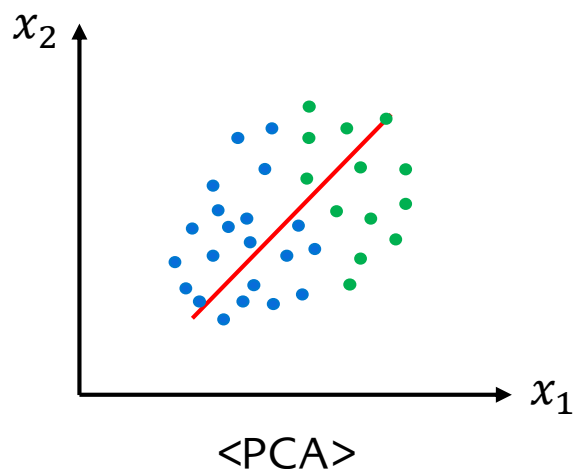
$$\frac{1}{n} K Z(h) = Z(h) \Lambda \quad (8.7)$$

가 되어 행렬  $K$ 의 고유벡터는  $Z(h)$ , 고유값은  $\Lambda$  됨.

- 이  $K_{ij} = h^T(x_i) h(x_j)$ 를 커널함수  $\kappa(x_i, x_j)$ 로 대체하는 커널속임수로 구하면  $Z(h)$ 의 값 또한 구할 수 있음. (8.6)에서 가장 큰  $l$ 개의 고유값에 대응하는 고유벡터를 이용하여 차원축소를 함.

## 03 Fisher's LDA (Linear Discriminant Analysis)

- 차원 축소에서 이용되는 방법 중 하나는 Fisher's LDA (Linear Discriminant Analysis)임.
- PCA는 특성변수  $X$ 만을 이용해 설명력이 높은 벡터를 찾는 반면 Fisher's LDA는  $y$ 의 class를 잘 분류해주는 벡터를 찾는 것이 목적임.



파란색은 class 1, 초록색은 class 2

## 특성변수가 $d$ 차원이고 class 수는 $c$ 인 경우

- $n_c$ : class  $C$ 의 관측치 수,  $\mathbf{x}_i^c$ : class  $C$ 에서  $i$ 번째 관측치

각 그룹 내의 특성변수의 평균  $\mathbf{m}_c = \frac{1}{n_c} \sum_{i=1}^{n_c} \mathbf{x}_i^c$ ,  $c = 1, 2, \dots, C$  임.

- 그러면 그룹 내 분산( $S_w$ )과 그룹 간 분산( $S_B$ )은

$$S_w = \sum_{c=1}^C S_c = \sum_{c=1}^C (\mathbf{x}_i^c - \mathbf{m}_c)(\mathbf{x}_i^c - \mathbf{m}_c)^T, \quad S_B = \sum_{c=1}^C n_c (\mathbf{m}_c - \mathbf{m})(\mathbf{m}_c - \mathbf{m})^T$$

임.

- $J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$  라고 정의하면 이 값이 크다는 것은 그룹 간 분산이

그룹 내 분산보다 크다는 것을 의미함

## 특성변수가 $d$ 차원이고 class 수는 $c$ 인 경우

- 그러므로  $J(w)$ 를 최대로 해주는  $w$ 를 찾으면 됨.

즉,  $\frac{d}{dw}[J(w)] = 0$ 인  $w$ 이므로 이를 정리하면  $S_w^{-1}S_B w = \lambda w$  임.

- $S_w^{-1}S_B$ 에 대한 고유벡터와 고유값을 구한 후 가장 큰  $l$ 개의 고유값에 대응하는 고유벡터를  $w_{d \times l}$  ( $l < d$ )라고 정의함.
- 마지막으로 이  $w$ 를 이용하여  $l$ 차원인 새로운 특성변수  $Z = Xw$ 를 생성함.

## 04 MDS (Multidimensional Scaling)


- 고차원에서 측정한 유클리디안(Euclidean) 거리뿐만 아니라 심리적, 감성적인 거리를 시각화가 가능한 1~3차원으로 재 표현하는 기법임.
- PCA의 경우 거리를 왜곡하지만 MDS는 거리를 그대로 옮겨옴.
- $x_1, x_2, \dots, x_n$ 을  $p$  차원의  $n$  개의 자료,  $d_{ij}$ 를  $x_i$  와  $x_j$ 의 거리라 하면 MDS는

$$\sum_{i=1}^n \sum_{j=1}^n (d_{ij} - \|z_i - z_j\|)^2 \quad (8.8)$$

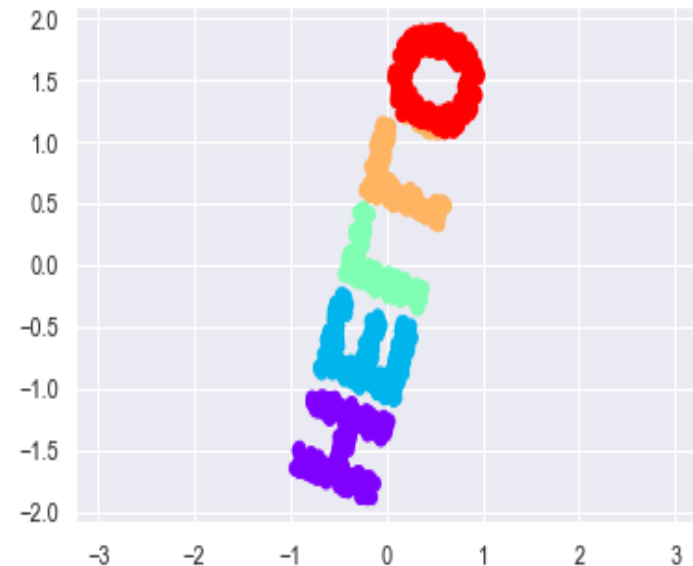
을 최소화하는  $z_i, i = 1, 2, \dots, n$ 을 찾는 것으로 요약됨. 이때

$\|z_i\| = \sqrt{z_{i1}^2 + \dots + z_{id}^2}$ 로 유클리디안 거리이며  $z_i$ 는 기울기 하강법으로 구함.

## 3차원의 HELLO에 대한 적용



<3차원의 HELLO>




<3차원의 HELLO를 MDS에 의해 차원 축소>


- 약간의 왜곡은 있지만 의미 전달에는 문제가 없음.



## 3차원의 HELLO에 대한 적용



<S자 커브 형태로 배열된 HELLO>



<S자 커브 형태로 배열된 HELLO를  
MDS에 의해 차원 축소>

- 비선형일 경우 앞에서 설명한 MDS는 작동하지 않음.

## 비선형 자료에 대한 MDS

- 해결 방법

- 1) K-nearest neighbors를 직선으로 가정하여 이들 자료에만 MDS를 적용하거나 선형 결합을 함.
- 2) 지도면 상의 최소 거리를 거리 측정함. 국지적으로 평면인 공간을 manifold라고 하기 때문에 이를 manifold 학습이라고 함.

# K-nearest neighbors 이용

- Local MDS
  - K-nearest neighbors를 이용하는 방법임.
  - MDS에 사용한 자료점  $x_i$  와 차원 축소 자료점  $z_i$  를 이용하며 Local MDS의 손실함수는

$$L = \sum_i \sum_j (1 - \lambda) (\|x_i - x_j\| - \|z_i - z_j\|)^2 I_{[\|z_i - z_j\| < \sigma_i]} + \lambda (\|x_i - x_j\| - \|z_i - z_j\|)^2 I_{[\|x_i - x_j\| < \sigma_i]} \quad (8.9)$$

이 됨. 이때  $0 \leq \lambda \leq 1$  이고 만약  $t < \sigma$  이면  $I_{[t < \sigma]} = 1$  이고 그렇지 않으면  $I_{[t < \sigma]} = 0$   
 $\lambda = 0$  에 가까우면 기존 특성변수,  $\lambda = 1$  에 가까우면 새로운 특성변수에 비중 둠.

## K-nearest neighbors 이용

- (8.9)식은  $I_{[\|z_i - z_j\| < \sigma_i]}$  는  $z_i$  를 중심으로 반지름이  $\sigma_i$  인 원 안에 포함된 자료만 최소화 하고  $I_{[\|x_i - x_j\| < \sigma_i]}$  역시  $x_i$  를 중심으로 일정 범위 안(궁극적으로 k-nearest neighbors)에 있는  $x_j$ 들과의 거리를 최소화 한다는 의미임.
- 확률적 기울기 강하법으로 손실함수를 최소화 하는  $z_i$  를 구하며  $\sigma_i$ 의 초기치는 모든 자료를 포함하도록 충분히 크게 부여하고 최종적으로 k-nearest neighbors가 되도록 설정함.
- 특히 (8.9)에서  $\lambda = 0$  이면 곡선성분분석(curvilinear component analysis, CCA)라고 함.

# K-nearest neighbors 이용

- Locally linear embedding (LLE)
  - 모든 자료점을  $k$ 개의 주변 자료의 선형결합으로 근사할 수 있다고 가정에서 출발하며

$$\sum_{i=1}^n \left\| \mathbf{x}_i - \sum_{j=1}^k w_{ij} \mathbf{x}_j \right\|^2 \quad (8.10)$$

를 최소화 하는  $w_{ij}$ 를 OLS로 구한 후(단,  $\sum_{j=1}^k w_{ij} = 1$ ) 이 를 이용해

$$\sum_{i=1}^n \left\| \mathbf{z}_i - \sum_{j=1}^k w_{ij} \mathbf{z}_j \right\|^2 \quad (8.11)$$

를 최소화 하는  $\mathbf{z}_i$ 를 구함.  $w_{ij} = 0, k < j \leq n$ 라고 하면  $w_{ij}$ 을 행렬  $W$ 로 표현할 수 있으며 (8.11)을 최소화 하는  $\mathbf{z}_i$ 는  $(I - W)^T(I - W)$ 의 두 번째로 작은 고유벡터가 됨.

# Manifold 학습법

- Isomap
  - 지도면 상의 최소 거리를 이용한 manifold 학습법임.
  - 자료점 각각의 k-nearest neighbors를 구한 후 이들을 선으로 연결한 후 이 선의 길이를 유클리디안 거리로 계산함.  $x_i$  와  $x_j$  의 거리는 이들 선들의 경로를 따라 최단 거리로 정의한 후 이 거리에 MDS를 적용하여 차원 축소함.
- 이외에도 확률적 거리를 기반으로 한 stochastic neighbor embedding (SNE) 등이 있으나 계속 속도가 느리고 LLE보다 성능이 떨어지는 것으로 나타나 자세한 내용은 생략함.

Q & A