

Machine Learning

10장 Regression Analysis

고려대학교 통계학과
박유성



Contents

- 01 선형회귀 모형
- 02 로버스트 회귀
- 03 SVM 회귀와 커널 SVM회귀
- 04 규제화된 선형회귀모형 & 기타 회귀모형
- 05 실습

01 선형회귀 모형

- 분류와 더불어 지도학습의 중요부분.
- 클래스(이산형) y 를 예측 \rightarrow 분류
- 연속형 y 를 예측 \rightarrow 회귀
- 해석이 용이하고 모수 추정이 쉬워 가장 널리 사용됨.
- 고전적 선형 회귀 모형.

$$y_i = \beta_0 + \beta_1 x_{1,i} + \cdots + \beta_d x_{d,i} + \varepsilon_i \quad (10.1)$$

이때 $i = 1, 2, \dots, n$: 관측치의 개수 x_1, \dots, x_d : d 개의 특성변수.

$$\varepsilon_i \sim iid(0, \sigma^2)$$

01 선형회귀 모형-선형성의 특징

- y와 x와의 관계가 선형 또는 비선형 상관없음.
- Y와 β 와의 관계가 선형일때 → 선형모형.
- 예 x_1, x_2 두 개의 특성변수가 있을 때

$$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{1,i}^2 + \beta_3 x_{1,i} x_{2,i} + \beta_4 e^{x_{2,i}} + \varepsilon_i \quad (10.2)$$

이때, $x_{1,i}^2 = x_{2,i}^*$, $x_{1,i} x_{2,i} = x_{3,i}^*$, $e^{x_{2,i}} = x_{4,i}^*$ 로 놓으면 선형모형으로 변환가능.

- 특성변수가 제곱의 형태 또는 지수의 형태 등 관계없음.
- Y와 특성 변수 각각에 대한 Scatter plot을 그린 후 특성변수의 변환.

01 선형회귀 모형-모형의 추정

- $$y_i = \beta_0 + \beta_1 x_{1,i} + \beta_2 x_{2,i} + \dots + \beta_d x_{d,i} + \varepsilon_i \quad , i = 1, 2, \dots, n \quad (10.3)$$
$$= \beta^T \mathbf{x}_i + \varepsilon_i$$

이때, $\mathbf{x}_i = (1, x_{1,i}, \dots, x_{d,i})^T$ 이고 $\beta = (\beta_0, \beta_1, \dots, \beta_d)^T$

- 오차항의 y_i 에 대한 영향력을 최소화

$$\sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta^T \mathbf{x}_i)^2 \quad (10.4)$$


- 식(10.4)를 최소화 하는 β 를 최소제곱추정치 또는 OLS라고 함.
- 머신러닝에서는 β 의 추정치를 기울기 하강법(Ch.2.3)을 이용하여 추정.
- 직접 β 를 추정하면,

$$\hat{\beta} = (X^T X)^{-1} X^T \mathbf{y}$$

- 특성 변수들이 선형적으로 독립이어야함. 즉 특성변수간 상관관계=0
- 특성 변수들 간의 상관 관계를 사전에 점검 하여야 함.

01 선형회귀 모형-모형의 진단

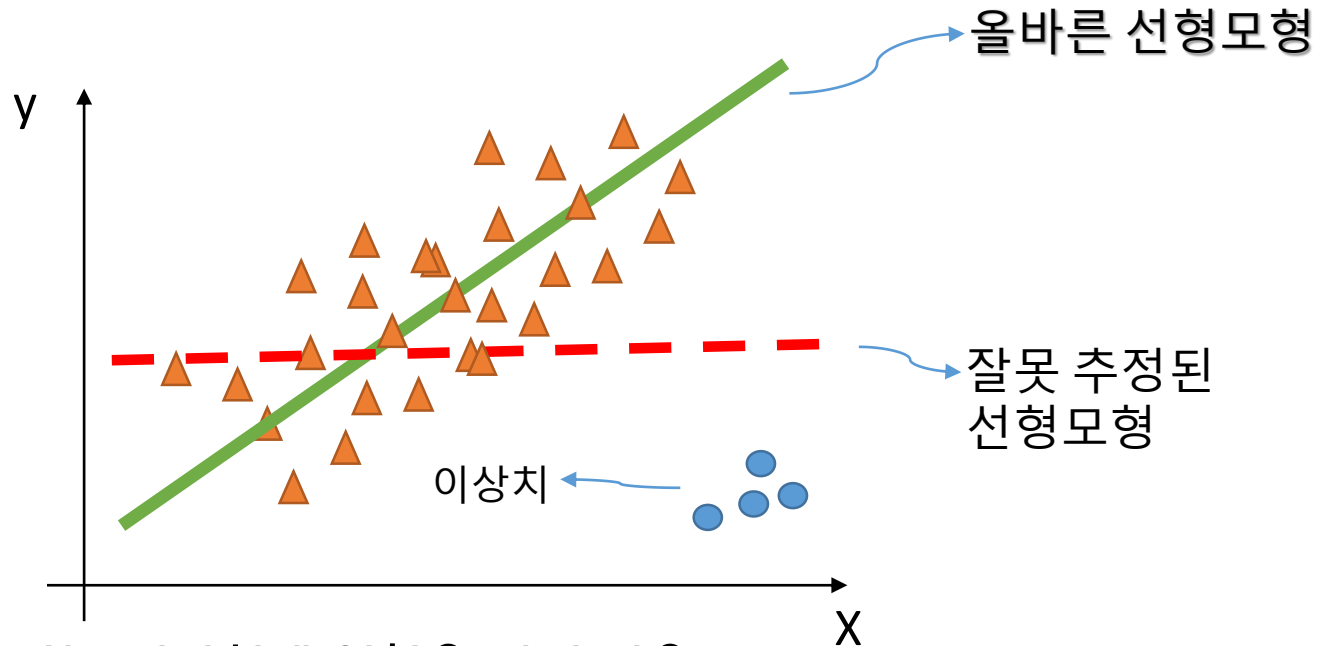
- 모형의 진단은 잔차 plot를 그려 보는 것으로 부터 출발.
- Y의 예측치 : $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1,i} + \dots + \hat{\beta}_d x_{d,i}$ 이고, 잔차 : $r_i = y_i - \hat{y}_i$ 일때,
- X축 $\rightarrow \hat{y}_i$, y축 $\rightarrow r_i$ 인 plot



- r_i 는 식(10.1)의 ε_i 의 추정치 이므로, 모형이 잘 추정됨 $\rightarrow r_i \sim iid(0, \sigma^2)$ 만족.
- r_i 가 추세 또는 특수한 형태를 가지면 모형을 재추정 해야함.

02 로버스트회귀(Robust regression model)

- 선형회귀모형은 이상치의 영향을 크게 받음. (∵ 오차항의 제곱합 최소화)



- 큰 오차를 갖는 이상치에 영향을 많이 받음.
- 따라서, 로버스트 회귀 방법을 사용해야함.
- 통계학 에서의 로버스트 회귀 : M-estimator, LTS, DPM 등.
- 머신러닝 에서의 로버스트 회귀 : RANSAC(random sample consensus)

02 로버스트회귀-RANSAC

- 매우 직관적이지만 이상치에 매우 로버스트함.


- RANSAC의 절차.

1. 학습데이터에서 작은 크기의 임의 표본을 뽑음.(특성변수 총수 + 20~30개의 표본)
2. 표본에 OLS추정치를 구함. 이후
3. 추정된 모형에 전체 학습데이터를 적용하여 잔차를 구함.
4. 잔차의 중위수(median)을 구한 후 각 잔차의 MAD ($|r_i - \text{median}(r_i)|$)를 구함.
5. MAD가 d (보통 4~5)보다 작은 관측치만 모음. → 콘센서스셋(consensus set)
6. 콘센서스셋에 OLS를 재적합.
7. step1~step6를 M번 반복한다.

- 가장 큰 크기의 콘센서스셋으로 계산된 OLS 추정치 → RANSAC
- MAD대신 절대값 등으로 대체 가능.
- 초모수 : 반복수 M, 임의의 표본수, 임계값 d (일종의 SVM으로 볼수 있음.)

03 SVM회귀 & 커널 SVM회귀 1

- SVM회귀의 목표 : 자료 (y_i, x_i) , $i = 1, 2, \dots, n$ 가 $|y_i - \beta_0 - \beta_1 x_i| \leq \epsilon_i$ 인 β_0 와 β_1 찾기.



- 이때 두 직선 사이 거리 : $y_+ - y_- + \beta^T(x_- - x_+) = 2\epsilon$

- 양변을 $\|\beta\| = \sqrt{\sum_{i=0}^d \beta_i^2}$ 으로 나누면(β^T 의 유일해)

$$\frac{(y_+ - y_-) + \beta^T(x_- - x_+)}{\|\beta\|} = \frac{2\epsilon}{\|\beta\|} \quad (10.5)$$

- 식(10.5)의 표준화 거리를 최대화 $\rightarrow (y_+, x_+)$ 와 (y_-, x_-) 사이의 거리를 최대화 하는 선형평면. \rightarrow 즉, (y_+, x_+) 와 (y_-, x_-) 가 서포트 벡터가 됨.


03 SVM회귀 & 커널 SVM회귀 2

- 표준화 거리의 최대화 = $\|\beta\|$ 의 최소화 = $\|\beta\|^2$ 의 최소화.
- 즉, $i = 1, 2, \dots, n$ 에 대해 $|y_i - \mathbf{x}_i^T \beta| \leq \epsilon$ 을 만족하는 $\|\beta\|^2$ 을 최소화 문제.
- SVM 분류와 개념적으로 동일.

- 그러나, 실제 문제에서 ϵ 이 매우 크지 않는 한 $|y_i - \mathbf{x}_i^T \beta| \leq \epsilon$ 만족 어려움.
- SVM에서와 같이 완화변수 (slack variable: ζ_i 와 ζ_i^*)도입 필요.

03 SVM회귀 & 커널 SVM회귀 3

- 완화 변수(slack variable)



$$y_i - \mathbf{x}_i^T \boldsymbol{\beta} \leq \epsilon + \zeta_i$$

$$\mathbf{x}_i^T \boldsymbol{\beta} - y_i \leq \epsilon + \zeta_i^* \quad \text{이때 } \zeta_i, \zeta_i^* \geq 0$$

- SVM 회귀의 최적화

$$\underset{\boldsymbol{\beta}}{\text{minimize}} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n (\zeta_i + \zeta_i^*)$$

$$y_i - \mathbf{x}_i^T \boldsymbol{\beta} \leq \epsilon + \zeta_i \text{ 와 } \mathbf{x}_i^T \boldsymbol{\beta} - y_i \leq \epsilon + \zeta_i^* \quad (10.6)$$

- 즉, ϵ -insensitive 손실함수

$$L(\boldsymbol{\beta}) = \sum_{i=1}^n L_\epsilon(y_i - \mathbf{x}_i^T \boldsymbol{\beta}) + \lambda \|\boldsymbol{\beta}\|^2 \quad \text{과 동일. Where } L_\epsilon(r) = \begin{cases} 0 & \text{if } |r| \leq \epsilon \\ |r| - \epsilon & \text{otherwise} \end{cases} \quad \lambda = \frac{1}{C}$$

- 즉, 튜브안($|y_i - \mathbf{x}_i^T \boldsymbol{\beta}| < \epsilon$)이면 0을 부여, 튜브 밖의 관측치에만 손실을 부여.

03 SVM회귀 & 커널 SVM회귀 4

- 라그랑지 승수 $\alpha_i, \alpha_i^*, \eta_i$ 와 η_i^* 를 이용하여 손실함수 정의.

$$L_p = \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^n (\zeta_i^* + \zeta_i) + \sum_{i=1}^n \alpha_i (y_i - \mathbf{x}_i^T \beta - \varepsilon - \zeta_i) + \sum_{i=1}^n \alpha_i^* (\mathbf{x}_i^T \beta - y_i - \varepsilon - \zeta_i^*) - \sum_{i=1}^n (\eta_i \zeta_i + \eta_i^* \zeta_i^*) \quad (10.7)$$

- L_p 를 최소화 하는 β, ζ_i 와 ζ_i^* 대해 미분.

$$\sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i = \beta, \quad \alpha_i = C - \eta_i, \quad \alpha_i^* = C - \eta_i^* \quad \text{이므로,}$$

- 이를 식(10.7)에 대입.

$$L_p = \varepsilon \sum_{i=1}^n (\alpha_i + \alpha_i^*) - \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*) + \frac{1}{2} \sum_{i,j=1}^n (\alpha_i^* - \alpha_i)(\alpha_j^* - \alpha_j) \mathbf{x}_i^T \mathbf{x}_j \quad (10.8)$$

- L_p 최소화하는 α_i 와 α_i^* 는 아래와 같은 조건에서 구함.

$$\alpha_i (y_i - \mathbf{x}_i^T \beta - \varepsilon - \zeta_i) = 0, \quad \alpha_i^* (\mathbf{x}_i^T \beta - y_i - \varepsilon - \zeta_i^*) = 0, \quad (C - \alpha_i) \zeta_i = 0, \quad (C - \alpha_i^*) \zeta_i^* = 0$$

- 이에 대한 해는 convex quadratic 프로그램 문제.

[계속]

03 SVM회귀 & 커널 SVM회귀 5

- ε -튜브안의 모든 관측치는 $\zeta_i = \zeta_i^* = 0$ 이고 $|y_i - \mathbf{x}_i^T \boldsymbol{\beta}| < \varepsilon$ 임.
- 따라서 조건 $\alpha_i(y_i - \mathbf{x}_i^T \boldsymbol{\beta} - \varepsilon - \zeta_i) = 0$ 와 $\alpha_i^*(\mathbf{x}_i^T \boldsymbol{\beta} - y_i - \varepsilon - \zeta_i^*) = 0$ 에 의해 ε -튜브안의 모든 관측치에 대한 $\alpha_i = \alpha_i^* = 0$ 됨.
- 이는 $\boldsymbol{\beta} = \sum_{i=1}^n (\alpha_i - \alpha_i^*) \mathbf{x}_i$ 이므로, ε -튜브안의 관측치는 $\boldsymbol{\beta}$ 에 기여하지 못함.
- 즉 ε -튜브 경계선 및 밖의 관측치만 $\boldsymbol{\beta}$ 를 구하는데 기여함.(즉, 서포트 벡터)
- 새로운 특성변수 \mathbf{x} 에 대한 y 예측치. Where : $y_i = \mathbf{x}_i^T \boldsymbol{\beta}$ 이고 $\hat{\boldsymbol{\beta}} = \sum_{i=1}^n (\hat{\alpha}_i - \hat{\alpha}_i^*) \mathbf{x}_i$

$$f(\mathbf{x}) = \sum_{i=1}^n (\hat{\alpha}_i - \hat{\alpha}_i^*) \mathbf{x}_i^T \mathbf{x} \quad (10.9)$$

- 비선형 커널 SVM회귀 : $\mathbf{x}_i^T \mathbf{x}_j$ 대신에 적절한 kernel 함수 $K(\mathbf{x}_i, \mathbf{x}_j)$ 를 대입.
- α_i 와 α_i^* 를 구한 후 비선형 커널 SVM회귀의 예측치는.

$$\hat{y}_i = \sum_{i=1}^n (\hat{\alpha}_i - \hat{\alpha}_i^*) K(\mathbf{x}_i, \mathbf{x})$$

04 규제화된 선형회귀모형과 기타 회귀모형 1

- 과적합(over fitting)의 문제 고려 하여야함.
- 리지(Ridge) 회귀.
- L_2 규제화를 살펴보면

$$\sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 + \lambda \sum_{j=1}^d \beta_j^2 \quad (10.10)$$

- 이때 L_2 규제화 에서의 $\boldsymbol{\beta}$ 임. 식(10.10)을 행렬식으로 표현하면,

$$L(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + \lambda \boldsymbol{\beta}^T \boldsymbol{\beta} \text{ 을 미분하면,}$$

$$\frac{\partial L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} + 2\lambda \boldsymbol{\beta} = 0 \text{ 을 풀면, } \hat{\boldsymbol{\beta}}_{Ridge} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

- 통계학 : $\mathbf{X}^T \mathbf{X}$ 의 역행렬이 존재하지 않을 때 적용.
- 해석의 문제가 발생하여 거의 쓰지 않는 방법
- L_2 규제화로 해석이 가능해짐. → 회귀모형의 과대적합 해결방안으로 유용.

04 규제화된 선형회귀모형과 기타 회귀모형 2

- **LASSO**(Least absolute shrinkage and selection operator)

- L_1 규제화를 살펴보면,

$$\sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 + \lambda \sum_{j=1}^d |\beta_j| \text{ 를 최소화 하는 } \boldsymbol{\beta} \text{ 를 구함.}$$

- 이때, λ 가 클수록 설명력이 작은 순서대로 $\beta_j \rightarrow 0$ 수렴.

- 즉, 특성변수를 선택하는 모형임.

- **Elastic Net** : L_1 규제화와 L_2 규제화를 결합한 선형회귀모형.

$$\sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 + \lambda_1 \sum_{j=1}^d |\beta_j| + \lambda_2 \sum_{j=1}^d \beta_j^2 \text{ 를 최소화 하는 } \boldsymbol{\beta} \text{ 를 구함.}$$

- 기타 회귀모형: KNN, 의사결정나무(회귀나무), Boosting을 이용한 회귀.

04 규제화된 선형회귀모형과 기타 회귀모형 3

- Scikit learn을 이용한 Ridge, LASSO, Elastic Net.

1.리지(Ridge)회귀.

```
from sklearn.linear_model import Ridge  
rd=Ridge(alpha=1.0)
```

alpha는 L_2 규제의 λ

2.LASSO

```
from sklearn.linear_model import Lasso  
lss=Lasso(alpha=1.0)
```

3. Elastic Net.

```
from sklearn.linear_model import ElasticNet  
elt=ElasticNet(alpha=1.0, l1_ratio=0.5)
```

alpha는 L_1 과 L_2 규제하의 $\lambda_1 + \lambda_2$

$l1_ratio$ 는 $\alpha \times l1_ratio$ 로 L_1 규제하의 λ_1

- 즉, $l1_ratio = 1 \rightarrow$ LASSO & $l1_ratio = 0 \rightarrow$ Ridge

04 규제화된 선형회귀모형과 기타 회귀모형 2

- **LASSO**(Least absolute shrinkage and selection operator)

- L_1 규제화를 살펴보면,

$$\sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 + \lambda \sum_{j=1}^d |\beta_j| \text{ 를 최소화 하는 } \boldsymbol{\beta} \text{ 를 구함.}$$

- 이때, λ 가 클수록 설명력이 작은 순서대로 $\beta_j \rightarrow 0$ 수렴.

- 즉, 특성변수를 선택하는 모형임.

- **Elastic Net** : L_1 규제화와 L_2 규제화를 결합한 선형회귀모형.

$$\sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 + \lambda_1 \sum_{j=1}^d |\beta_j| + \lambda_2 \sum_{j=1}^d \beta_j^2 \text{ 를 최소화 하는 } \boldsymbol{\beta} \text{ 를 구함.}$$

- 기타 회귀모형: KNN, 의사결정나무(회귀나무), Boosting을 이용한 회귀.

Q & A